



Instituto Tecnológico de Santiago del Estero

Tecnicatura Superior en Ciencia de Datos e Inteligencia Artificial

PROYECTO INTEGRADOR

INFORME FINAL

MINERÍA DE DATOS I — 2026



Integrantes:

- Daniela Fernández
- Julio Nahuel Gomez

Profesor:

- Fernando Elias Mubarqui

1. INTRODUCCIÓN

En este proyecto trabajamos con un dataset de usuarios de una plataforma de streaming. El objetivo fue aplicar todo lo visto en la materia: desde inspeccionar los datos hasta limpiarlos, analizarlos y presentar los resultados de forma clara. Cada decisión que tomamos la justificamos con lo que fuimos viendo en los datos, sin aplicar técnicas de forma automática.

2. DATASET

- **Archivo original:** streaming_users_dirty.csv (formato JSON)
- **Dimensiones originales:** 8.160 filas x 8 columnas
- **Dimensiones finales:** ~7.400 filas x 8 columnas
- **Variables:** user_id, age, subscription_plan, monthly_watch_time_mins, country, favorite_genre, last_login_date, customer_support_tickets

3. CALIDAD Y LIMPIEZA

Problemas detectados: 126 duplicados, 753 valores faltantes, 15 variantes en subscription_plan, 26 variantes en country, valores imposibles en age y monthly_watch_time_mins, valores centinela en customer_support_tickets.

Decisiones: eliminación de duplicados, normalización categórica, imputación con moda y mediana, eliminación de imposibles, parseo de fechas con format='mixed', winsorización k=1.5, eliminación de centinelas. Retención final ~90%.

4. ANÁLISIS EXPLORATORIO

- **Univariada 1:** Plan Básico concentra 44.8% de usuarios, Estándar 35.3%, Premium 19.9%.
- **Univariada 2:** Distribución de edades aproximadamente uniforme, sin concentración etaria.
- **Bivariado 1:** Usuarios Premium muestran mayor consumo mensual que Básico y Estándar.
- **Bivariado 2:** Preferencia de géneros homogénea entre países, con pequeñas variaciones culturales.
- **Multivariada:** No hay correlación lineal entre edad y consumo, pero el plan si muestra diferencias claras.

5. PCA

Variables: age, monthly_watch_time_mins, customer_support_tickets.

Escalamiento: StandardScaler (media=0, desvío=1). Las tres componentes explican el 100% de la varianza. El análisis de loadings mostro contribución diferenciada de cada variable.

6. CONCLUSIONES

- El plan Premium es el más asociado al mayor consumo de contenido.
- La edad no predice el tiempo de visualización.
- Las preferencias de genero son homogéneas entre países.
- Retención del ~90% preservando representatividad del dataset.

- Limitación: solo 3 variables numéricas acota el alcance del PCA.

7. ENLACES

- Repositorio: https://github.com/Danielafz/PI_Mineria_Datos_1
- Streamlit: <https://proyectointegradormineriadedatos1.streamlit.app/>